



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS
ENGENHARIA DA COMPUTAÇÃO
PROFESSOR DR. PEDRO THIAGO VALÉRIO DE SOUZA SISTEMAS INTELIGENTES

THIAGO GEOVANE DA COSTA NUNES

PROJETO 1: REDE ADALINE

PAU DOS FERROS – RN

2026

Sumário

1. INTRODUÇÃO	3
2. METODOLOGIA	3
4. CONCLUSÃO	5

1. INTRODUÇÃO

Repositório: https://github.com/Rated84/rede_adaline.git

Este trabalho tem como objetivo desenvolver um projeto de rede adaline para classificar automaticamente retornos da ionosfera, que seja capaz de realizar distinção de sinais que indicam a presença de estrutura eletrônica coerente na ionosfera daqueles que não a indicam.

2. METODOLOGIA

Para o treinamento foi feito uso do dataset Ionosphere, disponível no repositório UCI Machine Learning Repository (<https://archive.ics.uci.edu/ml/datasets/Ionosphere>). O conjunto de dados foi coletado pelo sistema de radar Goose bay, no Labrador (Canadá), e contribuído por Vince Sigilito do laboratório de Física Aplicada da Universidade Johns Hopkins.

Primeiramente foi carregado todo o dataset, seguido da separação dos atributos e da divisão de treino e teste com 80% e 20%. A implementação foi por meio da biblioteca sklearn. O treinamento foi conduzido com base na minimização do erro quadrático médio, ajustando os pesos via gradiente descendente.

Durante o treino foram avaliados os valores de hiperparâmetros como taxa de aprendizado e número de épocas.

3. RESULTADOS E DISCUSSÕES

1. Justificativa:

$$\Delta w = \eta(y_d - u)x$$

$$\text{logo: } |\Delta w| \propto \eta |e| |x|$$

Assim, quanto maior for $|x|$ maior será o passo dado entre os parâmetros. Quando os atributos tem escalas muito distintas, os gradientes também terão magnitudes muito diferentes entre as dimensões, fazendo a superfície de erro ser uma elipsoide muito alongada. Isso exige taxas de aprendizagem muito pequenas para evitar

divergência nas direções de grande variância, tornando o aprendizado extremamente lento nas demais.

Após a padronização Z-score — $x'=(x-\mu)/\sigma$ — cada atributo passa a ter média 0 e desvio padrão 1, tornando a superfície de erro aproximadamente esférica e garantindo que o gradiente descendente seja estável.

4. O erro mais crítico seria o falso negativo, pois seria uma classe bad representando ausência de estrutura ionosférica coerente. O que pode resultar em um sistema dando retorno good, permitindo a falha perpetuar, pois, o operador vai assumir que está havendo comunicação sendo que o canal está comprometido. Um falso positivo nesse caso geraria uma maior cautela na situação ocorrida.

4. CONCLUSÃO

O modelo apresentou bom desempenho na tarefa proposta, alcançando uma acurácia de 0,9577, indicando que realiza corretamente a maior parte das classificações. Observou-se também uma boa precisão e alto recall, destacando-se o fato de não terem ocorrido falsos negativos. Esse ponto é especialmente relevante para o contexto analisado, pois a ausência de falsos negativos evita situações de falsa confiança — como indicar que não há transmissão quando, na realidade, há.

Por outro lado, foram observados falsos positivos. Embora esses erros gerem alertas desnecessários, eles não são críticos no cenário em questão, pois apenas demandam verificações adicionais, sem comprometer diretamente a segurança ou a análise científica. Assim, o modelo prioriza corretamente a detecção de eventos relevantes, mesmo ao custo de alguns alarmes extras.

O F1-score apresentou um valor elevado, resultado do equilíbrio entre precisão e recall. Isso indica que o modelo mantém um bom desempenho geral, sendo capaz de identificar corretamente estruturas relevantes sempre que elas estão presentes, contribuindo para evitar perdas de comunicação e prejuízos na análise dos dados.

Além disso, o modelo mostrou-se adequado ao seu propósito: em situações críticas, como tempestades geomagnéticas, eventos importantes dificilmente passariam despercebidos devido ao alto recall.

Entretanto, a estratégia adotada para a escolha da taxa de aprendizado (η), baseada apenas no erro final, apresenta uma limitação. Esse critério considera apenas o valor final da curva de erro, ignorando sua trajetória ao longo do treinamento. Como ele não faz falsos negativos, em uma situação como tempestades geomagnéticas, não passaria despercebido, o modelo atende a seu propósito. Faz a escolha do η pegando o que gera o menor erro no final, porém isso revela outra coisa do modelo, o mesmo apenas ver o último ponto da curva não sua trajetória, o que pode acarretar em um η terminar rápido e não convergir e outro ir lento mas terminar melhor, ou seja, escolher um η que não é bom.